

Laporan Praktikum Kontrol Cerdas

Nama : Wafa Nabila Ulina Khoirunnisa
NIM : 224308024
Kelas : TKA 6A
Akun Github (Tautan) : <https://github.com/wafanabila>
Student Lab Assistant : Yulia Brilianty

1. Judul Percobaan

Pembelajaran Penguatan untuk Kontrol Otonom

2. Tujuan Percobaan

Tujuan dilakukannya Praktikum Kontrol Cerdas Klasifikasi Objek dengan Scikit-learn adalah Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.

1. Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
2. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
3. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
4. Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Pembelajaran Penguatan (Reinforcement Learning, RL) adalah pendekatan pembelajaran mesin di mana agen belajar melalui interaksi dengan lingkungan untuk memaksimalkan imbalan kumulatif (Sutton and Barto, 2015). Dalam kontrol otonom, RL digunakan untuk memungkinkan sistem mengambil keputusan secara independen tanpa intervensi manusia, yang sangat penting dalam berbagai aplikasi seperti robotika dan kendaraan otonom (Kober et al., n.d.). Salah satu algoritma RL yang paling dikenal adalah *Q-Learning*, di mana agen memperbarui estimasi nilai tindakan dalam suatu keadaan berdasarkan pengalaman yang dikumpulkan. Namun, ketika ruang keadaan dan tindakan sangat besar, pendekatan berbasis tabel seperti Q-Learning menjadi tidak efisien. Oleh karena itu, metode berbasis pembelajaran mendalam seperti Deep Q-Networks (DQN) telah dikembangkan untuk mengatasi permasalahan tersebut (Mnih et al., 2015).

Pendekatan RL juga telah berhasil diterapkan dalam berbagai sistem kontrol otonom. Dalam robotika, RL memungkinkan robot untuk belajar tugas-tugas kompleks seperti manipulasi objek dan interaksi manusia-robot (Levine et al., n.d.). Sementara itu, dalam kendaraan otonom, RL digunakan untuk optimasi navigasi, penghindaran rintangan, dan pengambilan keputusan secara real-time (Lillicrap et al., 2019).

Meskipun memiliki banyak keunggulan, penerapan RL dalam kontrol otonom masih menghadapi berbagai tantangan, seperti masalah eksplorasi yang efisien, stabilitas pembelajaran, serta aspek keamanan dalam pengambilan keputusan. Oleh karena itu, penelitian dalam bidang ini terus berkembang untuk meningkatkan efisiensi dan keandalan sistem berbasis RL.

4. Analisis dan Diskusi

Performa agen dalam mengendalikan lingkungan CartPole sangat bergantung pada seberapa baik model Deep Q-Network (DQN) dilatih. Jika agen mampu menjaga keseimbangan tiang selama periode yang lama, skor episode akan mendekati batas maksimum 500, yang menandakan bahwa agen telah memahami strategi optimal. Sebaliknya, skor episode yang rendah (misalnya di bawah 200) menunjukkan bahwa agen belum mampu mempertahankan keseimbangan dengan baik. Dalam kode yang disediakan, agen menerapkan ϵ -greedy policy dengan epsilon (ϵ) = 0.01, yang berarti agen cenderung lebih sering mengeksplorasi aksi terbaik berdasarkan pengalaman yang telah dipelajari. Meskipun pendekatan ini cocok untuk pengujian, pada tahap pelatihan, nilai ϵ yang lebih tinggi diperlukan agar agen dapat mengeksplorasi lebih banyak aksi sebelum menemukan strategi yang optimal.

Dalam reinforcement learning, beberapa parameter memiliki dampak signifikan terhadap kinerja agen. Epsilon (ϵ) mengontrol keseimbangan antara eksplorasi dan eksploitasi; nilai tinggi (misalnya 1.0 di awal pelatihan) memungkinkan agen untuk mencoba aksi-aksi baru, sementara nilai rendah (seperti 0.01) membuat agen lebih terfokus pada strategi yang telah dipelajari sebelumnya. Discount factor (γ) mempengaruhi sejauh mana agen

mempertimbangkan reward jangka panjang—nilai tinggi (misalnya 0.99) mendorong agen untuk lebih fokus pada keuntungan jangka panjang, sedangkan nilai rendah (misalnya 0.8) membuat agen lebih mengutamakan reward instan. Selain itu, learning rate (α) menentukan kecepatan agen dalam memperbarui kebijakannya; nilai yang terlalu tinggi dapat menyebabkan pembelajaran menjadi tidak stabil, sedangkan nilai yang terlalu rendah dapat memperlambat konvergensi.

Dalam proses pelatihan agen Reinforcement Learning (RL) di CartPole, terdapat beberapa tantangan utama. Salah satunya adalah ketidakseimbangan antara eksplorasi dan eksploitasi; jika ϵ terlalu rendah, agen akan kurang melakukan eksplorasi terhadap strategi baru, namun jika terlalu tinggi, agen akan terlalu sering bertindak secara acak. Selain itu, ketidakstabilan dalam pelatihan DQN bisa terjadi jika parameter seperti γ atau α tidak diatur dengan baik, yang dapat menyebabkan osilasi dalam proses pembelajaran. Agen juga berpotensi mengalami overfitting pada reward jangka pendek, dengan lebih memfokuskan perhatian pada tindakan yang menghasilkan reward instan tanpa mempertimbangkan strategi jangka panjang. Variabilitas dalam lingkungan juga menuntut agen untuk dapat menggeneralisasi strateginya agar tetap efektif dalam berbagai kondisi awal. Untuk mengatasi tantangan-tantangan ini, teknik seperti Replay Buffer dan Target Network dapat digunakan untuk menstabilkan pembelajaran, serta melatih agen dengan beragam kondisi awal agar lebih adaptif. Jika performa agen masih rendah, diperlukan pelatihan ulang dengan parameter yang lebih optimal untuk meningkatkan stabilitas dan efektivitas dalam proses pembelajaran.

Perbedaan utama antara Reinforcement Learning (RL) dan Supervised Learning dalam sistem kendali terletak pada cara agen memperoleh pengetahuan. Dalam Supervised Learning, model dilatih menggunakan data berlabel yang sudah tersedia, sehingga sistem belajar berdasarkan pola yang ada dalam dataset. Sebaliknya, RL tidak memerlukan data berlabel, melainkan belajar melalui interaksi dengan lingkungan dan menerima umpan balik dalam bentuk reward untuk menyesuaikan tindakannya. Dalam RL, strategi eksplorasi (exploration) dan eksploitasi (exploitation) perlu dioptimalkan agar agen dapat menemukan strategi terbaik. Eksplorasi memungkinkan agen mencoba aksi baru untuk menemukan solusi yang lebih baik, sementara eksploitasi membuat agen menggunakan strategi terbaik yang telah ditemukan sejauh ini. Pendekatan seperti ϵ -greedy policy, di mana agen mulai dengan eksplorasi tinggi dan secara bertahap beralih ke eksploitasi, atau metode lebih canggih seperti Upper Confidence Bound (UCB) dan Thompson Sampling, dapat meningkatkan keseimbangan antara eksplorasi dan eksploitasi. RL memiliki banyak potensi aplikasi dalam sistem kendali nyata, seperti kendali robot otonom, optimasi konsumsi energi dalam bangunan pintar, manajemen lalu lintas, dan pengendalian sistem industri. Dalam dunia transportasi, RL dapat digunakan untuk optimasi rute kendaraan otonom, sedangkan dalam industri manufaktur, dapat membantu dalam kontrol kualitas dan pemeliharaan prediktif, meningkatkan efisiensi dan mengurangi biaya operasional.

5. Assignment

Pada praktikum ini, algoritma Deep Q-Network (DQN) diterapkan untuk melatih agen dalam lingkungan MountainCar-v0. Tujuan utama agen adalah mencapai puncak bukit dengan memilih aksi yang paling optimal. Implementasi kode dimulai dengan mengimpor berbagai pustaka yang diperlukan, antara lain gymnasium untuk mengelola lingkungan pembelajaran penguatan, numpy untuk operasi numerik, random untuk pemilihan aksi secara acak, serta deque dari collections untuk menyimpan pengalaman agen. Selain itu, tensorflow.keras digunakan untuk membangun dan melatih model jaringan saraf.



Agen DQN didefinisikan dalam kelas bernama DQNAgent, yang diinisialisasi berdasarkan ukuran keadaan dan jumlah aksi yang tersedia. Beberapa parameter utama dalam algoritma ini terdiri dari gamma sebagai faktor diskon untuk reward di masa depan, epsilon untuk mekanisme eksplorasi, dan learning rate yang menentukan kecepatan optimasi model.

Pada eksperimen pertama, yaitu CartPole-V1, agen bertugas menjaga keseimbangan tiang di atas gerobak. Lingkungan ini relatif sederhana dan lebih dapat diprediksi, sehingga agen dapat belajar dengan cepat. Setiap kali agen berhasil menjaga tiang tetap tegak, ia akan mendapatkan reward positif. Pelatihan untuk CartPole dapat diselesaikan dalam beberapa ratus episode, karena agen dengan mudah mencapai performa optimal.

Di sisi lain, tantangan dalam MountainCar-v0 lebih kompleks. Agen harus menggerakkan mobil ke puncak bukit, namun tenaga mobil tidak cukup untuk langsung mencapai tujuan tersebut. Karena itu, agen perlu membangun momentum dengan bergerak maju dan mundur secara strategis. Reward dalam lingkungan ini lebih sulit diperoleh, karena agen sering kali gagal mencapai puncak bukit di awal pembelajaran. Tingkat kesulitan yang lebih tinggi di

MountainCar-v0 memerlukan arsitektur model yang lebih kompleks atau teknik tambahan untuk meningkatkan stabilitas pelatihan. Proses belajar dalam lingkungan ini juga membutuhkan lebih banyak episode sebelum agen dapat mencapai performa optimal. Selain itu, nilai reward yang diperoleh dapat sangat fluktuatif, sehingga diperlukan penyesuaian lebih lanjut agar agen dapat meraih skor yang lebih tinggi secara konsisten.

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan
1	Hasil Score DQN	<pre>Episode: 15/50, Score: 41, Epsilon: 0.94 Episode: 16/50, Score: 25, Epsilon: 0.93 Episode: 17/50, Score: 21, Epsilon: 0.93 Episode: 18/50, Score: 18, Epsilon: 0.92 Episode: 19/50, Score: 15, Epsilon: 0.92 Episode: 20/50, Score: 30, Epsilon: 0.91 Episode: 21/50, Score: 17, Epsilon: 0.91 Episode: 22/50, Score: 11, Epsilon: 0.90 Episode: 23/50, Score: 9, Epsilon: 0.90</pre>
2	Hasil Score Test	<pre>if not isinstance(termina Test Episode: 1, Score: 7 Test Episode: 2, Score: 7 Test Episode: 3, Score: 8 Test Episode: 4, Score: 7 Test Episode: 5, Score: 9 DO DAILY MOUNTAIN SEMESTER 0.0.0.0</pre>
3	Hasil Run Cartpole	
4	Hasil Run Mountain Car	

7. Kesimpulan

Penggunaan target network berperan penting dalam meningkatkan stabilitas proses pembelajaran, dengan mencegah perubahan nilai Q yang terlalu drastis. Di sisi lain, lingkungan MountainCar-v0 lebih menantang untuk dipelajari karena reward hanya diberikan ketika agen mencapai puncak bukit. Hal ini mengharuskan agen untuk melakukan eksplorasi yang lebih lama dan mengandalkan momentum agar dapat berhasil. Sebaliknya, dalam lingkungan

Cartpole, proses pembelajaran berlangsung lebih cepat karena agen dapat menerima reward pada setiap langkah yang dilakukan, sehingga menjadikannya lebih optimal.

8. Saran

Untuk meningkatkan performa agen DQN, salah satu pendekatan yang dapat diterapkan adalah penggunaan Target Network. Metode ini bertujuan untuk meningkatkan stabilitas model dan mencegah terjadinya overfitting terhadap pola jangka pendek, dengan cara memperbarui Target Network secara berkala. Selain itu, implementasi strategi epsilon decay yang lebih adaptif, yang disesuaikan berdasarkan performa, dapat memperbaiki keseimbangan antara eksplorasi dan eksploitasi. Pengoptimalan hyperparameter seperti gamma, learning rate, dan epsilon juga sangat penting untuk mencapai hasil yang lebih baik.

9. Daftar Pustaka

Kober, J., Bagnell, J.A., Peters, J., n.d. Reinforcement Learning in Robotics: A Survey.

Levine, S., Finn, C., Darrell, T., Abbeel, P., n.d. End-to-End Training of Deep Visuomotor Policies.

Lillicrap, T.P., Hunt, J.J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D., Wierstra, D., 2019. Continuous control with deep reinforcement learning. <https://doi.org/10.48550/arXiv.1509.02971>

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A.A., Veness, J., Bellemare, M.G., Graves, A., Riedmiller, M., Fidjeland, A.K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., Hassabis, D., 2015. Human-level control through deep reinforcement learning. *Nature* 518, 529–533. <https://doi.org/10.1038/nature14236>

Sutton, R.S., Barto, A.G., 2015. Reinforcement Learning: An Introduction.

.